

Avaliação Temporal Automatizada para o Framework VOID

Uma Melhoria Reprodutível para Análise de Consistência em Vídeo

Arthur Fillipe de Lira Aleixo
Departamento de Computação
Universidade Federal Rural de Pernambuco
Recife, Brasil

Resumo—Este trabalho apresenta uma melhoria de implementação no framework VOID para remoção de objetos em vídeo, introduzindo um módulo de avaliação temporal automática. O fluxo original privilegia avaliação visual e qualitativa, o que dificulta comparações objetivas entre configurações de inferência. Para mitigar esse problema, implementou-se um módulo que calcula métricas de coerência temporal entre frames consecutivos e exporta resultados em formatos estruturados (JSON e CSV). As métricas adotadas foram LPIPS temporal, consistência por fluxo óptico, PSNR consecutivo e SSIM consecutivo. A melhoria foi integrada ao código do framework e validada funcionalmente em ambiente Colab. Embora a execução completa do pipeline de inferência do VOID em configuração alvo tenha sido limitada por hardware no ambiente gratuito, a contribuição proposta foi implementada, testada e documentada com sucesso, provendo base quantitativa para experimentos futuros.

Index Terms—visão computacional, consistência temporal, métricas de vídeo, inpainting de vídeo, avaliação automática, reprodutibilidade

I. INTRODUÇÃO

A remoção de objetos em vídeo é um problema relevante em visão computacional aplicada, com impacto em produção audiovisual, restauração de conteúdo e edição automatizada. O desafio principal não é somente preencher corretamente uma região em um frame isolado, mas manter consistência espaço-temporal ao longo da sequência, evitando artefatos como flicker, jitter e mudanças estruturais abruptas.

Com o crescimento de modelos generativos para vídeo, frameworks mais sofisticados passaram a considerar contexto temporal e condições semânticas mais ricas. O framework VOID (Video Object and Interaction Deletion), da Netflix Research, destaca-se por tratar a remoção de objetos e seus efeitos de interação, em vez de apenas realizar inpainting local.

Apesar da qualidade visual dos resultados, uma lacuna operacional importante permanece: em diversos cenários de uso, a avaliação final ainda é majoritariamente subjetiva e visual. Isso dificulta:

- reprodução de experimentos;
- comparação objetiva entre variantes;
- comunicação quantitativa de ganhos.

Este projeto aborda essa lacuna com uma melhoria de implementação focada em avaliação temporal automática.

A. Problema

O problema central tratado é a ausência de um módulo padronizado, reprodutível e de baixo acoplamento para medição de coerência temporal no fluxo de inferência do VOID.

B. Hipótese

A hipótese de trabalho é que a integração de métricas temporais complementares, com exportação estruturada dos resultados, melhora a qualidade metodológica dos experimentos sem exigir alteração no núcleo gerativo do modelo.

C. Objetivos

Objetivo geral: implementar e validar um módulo de avaliação temporal automática integrado ao framework VOID.

Objetivos específicos:

- calcular LPIPS temporal, consistência por fluxo óptico, PSNR e SSIM frame-a-frame;
- gerar arquivos JSON e CSV para análise e auditoria;
- preservar compatibilidade com o fluxo original do framework;
- documentar limitações de infraestrutura e impactos no escopo experimental.

D. Contribuições

As contribuições efetivas deste trabalho são:

- 1) projeto e implementação de um módulo temporal reutilizável;
- 2) integração do módulo ao fluxo de inferência;
- 3) validação funcional em vídeo real de exemplo;
- 4) consolidação de um protocolo de reprodutibilidade.

II. CONTEXTO E TRABALHOS RELACIONADOS

A. VOID e remoção de objetos em vídeo

O VOID foi proposto para remover objetos e interações associadas em sequências de vídeo, com foco em plausibilidade temporal. Sua estrutura em duas passagens favorece refinamento de continuidade ao longo da sequência.

B. Avaliação visual versus avaliação quantitativa

A avaliação visual é relevante em tarefas generativas, mas possui limitações:

- alta variabilidade entre avaliadores;
- baixa escalabilidade para múltiplos experimentos;
- dificuldade em detectar pequenas regressões temporais;
- rastreabilidade limitada para replicação.

Assim, uma camada quantitativa temporal é desejável para complementar a avaliação qualitativa.

C. Métricas de referência

As métricas selecionadas representam diferentes dimensões:

- **LPIPS temporal**: distância perceptual entre frames adjacentes.
- **Flow consistency**: erro de reconstrução após warp com fluxo óptico.
- **PSNR consecutivo**: semelhança pixelwise.
- **SSIM consecutivo**: semelhança estrutural local.

A combinação dessas métricas reduz viés de interpretação baseada em um único indicador.

III. METODOLOGIA

A. Estratégia de implementação

A melhoria foi tratada como camada de instrumentação, mantendo o modelo gerativo inalterado. O objetivo foi minimizar acoplamento e risco de regressão no pipeline principal.

B. Design do módulo

O módulo `temporal_metrics.py` implementa:

- normalização de dados;
- avaliação por pares ($t, t + 1$);
- cálculo das quatro métricas;
- agregação estatística;
- persistência dos resultados.

C. Fluxo operacional

- 1) Entrada: tensor de vídeo gerado ou fornecido para validação.
- 2) Conversão para formato temporal canônico.
- 3) Processamento por pares consecutivos.
- 4) Cálculo das métricas por par.
- 5) Cálculo de média, desvio, mín e máx.
- 6) Gravação de JSON e CSV.

D. Integração ao framework

A integração ocorreu em pontos de inferência com tensor de vídeo já disponível, evitando leitura redundante de arquivo. Também foram adicionados controles para habilitar/desabilitar avaliação temporal e ajustar parâmetros do módulo em execução.

IV. CONFIGURAÇÃO EXPERIMENTAL

A. Ambiente

- plataforma: Google Colab;
- GPU: Tesla T4;
- VRAM: aproximadamente 14.56 GB;
- sistema: runtime Linux gerenciado.

B. Dados de validação

A validação funcional foi executada sobre `sample/lime/input_video.mp4`, com recorte de 8 frames (7 pares consecutivos). Esse protocolo foi escolhido para:

- permitir teste completo do módulo;
- reduzir custo computacional;
- manter rastreabilidade dos resultados.

C. Critérios de sucesso

Foram considerados critérios de sucesso:

- execução sem erro do módulo;
- presença das quatro métricas em todos os pares;
- geração de JSON e CSV;
- coerência entre resumo agregado e série por par.

V. RESULTADOS

A. Resultados agregados

A Tabela I resume os resultados para 8 frames (7 pares).

Tabela I
RESUMO DAS MÉTRICAS TEMPORAIS

Métrica	Média	Desvio	Mín	Máx
LPIPS temporal	0.01894	0.00505	0.01024	0.02638
Flow consistency L1	0.00562	0.00084	0.00440	0.00707
PSNR consecutivo	28.6320	1.7263	26.2697	31.6952
SSIM consecutivo	0.92535	0.02340	0.88417	0.95982

B. Curvas por par de frames

A Figura 1 mostra o comportamento das métricas ao longo da sequência validada.




Figura 1. Evolução das métricas por par de frames.

C. Análise dos valores

Os resultados indicam:

- estabilidade perceptual razoável (LPIPS temporal baixo);
- boa coerência de movimento (erro de fluxo reduzido);
- alta similaridade entre frames consecutivos (PSNR elevado);
- preservação estrutural consistente (SSIM alto).

D. Artefatos produzidos

A execução gerou:

- lime_input_video_temporal_metrics.json
- lime_input_video_temporal_metrics_pairs.csv

Esses arquivos garantem rastreabilidade e reutilização dos resultados.

VI. DISCUSSÃO

A. Impacto da melhoria no fluxo experimental

A principal contribuição desta melhoria não é alterar o núcleo gerativo do VOID, mas fortalecer a qualidade metodológica do processo experimental. Em vez de depender somente de avaliação visual subjetiva, o pipeline passa a produzir indicadores quantitativos por frame e agregados por vídeo. Isso torna possível comparar execuções distintas com rastreabilidade, reduzindo ambiguidades de interpretação.

No contexto acadêmico, esse tipo de instrumentação é particularmente importante porque transforma uma análise descritiva em análise mensurável. Em outras palavras, o trabalho passa a ter resultados numéricos auditáveis, o que facilita validação por terceiros e reprodução por outros estudantes.

B. Complementaridade das métricas

As quatro métricas escolhidas atuam em dimensões diferentes:

- LPIPS temporal: estabilidade perceptual entre frames adjacentes;
- Flow consistency: coerência de movimento;
- PSNR: similaridade energética pixelwise;
- SSIM: similaridade estrutural local.

A combinação evita viés de avaliação por métrica única. Por exemplo, um vídeo pode ter PSNR alto e ainda assim apresentar desconforto perceptual temporal, o que tende a ser melhor capturado por LPIPS e consistência por fluxo.

C. Interpretação dos resultados obtidos

Com base no experimento de validação funcional, os valores agregados indicaram comportamento temporal coerente no clipe analisado:

- LPIPS médio baixo, sugerindo boa continuidade perceptual;
- erro médio de fluxo baixo, sugerindo boa estabilidade dinâmica;
- PSNR médio relativamente alto para pares consecutivos;
- SSIM médio elevado, indicando preservação estrutural.

A variação por par de frame, observada no CSV, também foi consistente com transições de movimento natural no vídeo. Em pares mais desafiadores, houve aumento local de erro e redução de PSNR/SSIM, seguido de recuperação em pares subsequentes.

D. Limitação de hardware e impacto no escopo

Durante tentativas de execução completa do pipeline de inferência do VOID no Colab gratuito (Tesla T4 com aproximadamente 14.56 GB de VRAM), o processo foi encerrado por memória insuficiente (*exit code 137*). Essa limitação impacta especificamente experimentos de inferência pesada em escala maior.

Entretanto, é importante destacar que tal restrição não invalida a contribuição implementada. O módulo de avaliação temporal foi integrado e validado funcionalmente, com geração correta dos artefatos e consistência dos resultados numéricos.

E. Ameaças à validade

Validade interna: o experimento funcional utilizou recorte curto (8 frames), o que reduz diversidade temporal. Ainda assim, o objetivo desta etapa foi validação de funcionamento do módulo, e esse objetivo foi cumprido.

Validade externa: generalização para múltiplos cenários depende de novas execuções com vídeos variados e, idealmente, ambiente de maior VRAM para comparações completas entre diferentes configurações do VOID.

Validade de construto: métricas automáticas representam proxies quantitativos de qualidade temporal e não substituem completamente avaliação humana. A estratégia recomendada é usar ambos de forma complementar.

VII. ANÁLISE DETALHADA POR PAR DE FRAMES

Para complementar o resumo agregado, a Tabela II apresenta os valores por par de frames consecutivos. Esse detalhamento é útil para identificar onde ocorrem picos locais de erro e como isso afeta cada métrica.

Tabela II
MÉTRICAS TEMPORAIS POR PAR DE FRAMES

t	LPIPS	Flow	PSNR	SSIM
0	0.01825	0.00521	29.9854	0.95063
1	0.02638	0.00707	26.7630	0.90990
2	0.01887	0.00524	28.2135	0.92054
3	0.02485	0.00659	26.2697	0.88417
4	0.01548	0.00440	29.1791	0.93106
5	0.01849	0.00554	28.3179	0.92130
6	0.01024	0.00529	31.6952	0.95982

Observa-se que os pares $t = 1$ e $t = 3$ concentram os maiores valores de LPIPS e erro de fluxo, acompanhados das menores faixas de PSNR/SSIM. Já o par $t = 6$ apresenta o melhor comportamento conjunto, com menor LPIPS e maior SSIM, sugerindo transição visualmente mais estável.

VIII. PLANO DE REPRODUTIBILIDADE

A. Organização recomendada

Para garantir reprodução por terceiros:

- manter notebooks separados por objetivo (integração e validação);
- versionar código da melhoria e testes;
- armazenar artefatos JSON/CSV e figuras no repositório.

B. Passos de reprodução

- 1) Clonar o repositório do projeto e configurar ambiente Python.
- 2) Instalar dependências necessárias para o módulo temporal.
- 3) Executar notebook de validação do módulo em vídeo real de exemplo.
- 4) Confirmar geração de:
 - arquivo JSON com resumo agregado e série temporal;
 - arquivo CSV com métricas por par de frames.
- 5) Comparar os valores produzidos com os intervalos reportados neste artigo.
- 6) Validar consistência estrutural dos campos: `video_name`, `num_frames`, `num_pairs`, `summary` e `pairs`.

C. Critérios de verificação

A reprodução é considerada válida se:

- as quatro métricas forem calculadas;
- arquivos de saída forem gerados corretamente;
- estrutura e campos de JSON/CSV coincidirem com a especificação.

IX. CHECKLIST DE ENTREGA

A. Itens para disciplina

Tabela III
CHECKLIST DE ENTREGA DO PROJETO

Item	Status
Melhoria implementada no framework	✓
Módulo de métricas temporais funcional	✓
Saída JSON gerada	✓
Saída CSV gerada	✓
Notebook de integração documentado	✓
Notebook de validação documentado	✓
Repositório organizado no GitHub	✓
Relatório no formato IEEE	✓
Vídeo de apresentação (até 10 min)	pendente

B. Itens para repositório

- `README.md` com objetivo, motivação, metodologia e limitações;
- pasta `docs/` com proposta, resultados, discussão e conclusão;
- pasta `notebooks/` com:
 - notebook de integração no framework;
 - notebook de validação isolada do módulo;
- pasta `outputs/` com JSON/CSV exportados;
- pasta `article/` com fonte LaTeX e PDF final.

X. CONCLUSÃO

Este trabalho implementou e validou uma melhoria de avaliação temporal automatizada no framework VOID, com cálculo de LPIPS temporal, consistência por fluxo óptico, PSNR e

SSIM por par de frames, além de exportação reproduzível em JSON e CSV.

A contribuição foi comprovada funcionalmente, com resultados quantitativos consistentes e rastreáveis, apesar das limitações de VRAM para execução completa do pipeline pesado no Colab gratuito.

XI. TRABALHOS FUTUROS

Como continuidade, recomenda-se:

- executar comparações Pass 1 vs Pass 2 em GPU com maior VRAM;
- ampliar conjunto de vídeos e cenários;
- adicionar agregações estatísticas multi-vídeo;
- incluir geração automática de relatório visual no pipeline.

AGRADECIMENTOS

Agradecimentos à disciplina de Visão Computacional da UFRPE pela proposta prática de reprodução e melhoria de sistemas de estado da arte.

REFERÊNCIAS

- [1] S. Motamed, W. Harvey, B. Klein, L. Van Gool, Z. Yuan, and T.-Y. Cheng, “VOID: Video Object and Interaction Deletion,” arXiv preprint arXiv:2604.02296, 2026.
- [2] Netflix Research, “void-model,” GitHub repository, 2025. [Online]. Available: <https://github.com/Netflix/void-model>
- [3] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, “The Unreasonable Effectiveness of Deep Features as a Perceptual Metric,” in *CVPR*, 2018.
- [4] Z. Teed and J. Deng, “RAFT: Recurrent All-Pairs Field Transforms for Optical Flow,” in *ECCV*, 2020.
- [5] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image Quality Assessment: From Error Visibility to Structural Similarity,” *IEEE Trans. Image Process.*, vol. 13, no. 4, pp. 600–612, 2004.
- [6] R. Szeliski, *Computer Vision: Algorithms and Applications*, 2nd ed. Springer, 2022.